



3. [3] 모집단에 대하여 표본 추출을 수행할 때 전수조사를 수행해야 하는 것은?

1 바다에 사는 고래 수

2 우주선의 부품 검사

3 암 발생률 통계 연구를 위한 환자의 암 진단

4 전구의 성능 조사

보기 3 수정

전수조사 수행해야 하는 때

- 조사 대상이 매우 적을 때(어떤 기업의 전체 임직원 만족도 조사), 국가 통계와 같이 법적, 제도적 근거가 있을 때(인구주택총조사)
- 결함이 있으면 치명적인 문제를 일으키는 때 : 항공기/우주선의 부품 검사, 원자력 발전소 안전 점검
- 데이터가 자동으로 수집될 수 있을 때 : POS 시스템의 모든 판매기록, 웹사이트의 로그데이터
- 우주선의 부품 검사 : 생명과 직결될 수 있어 전수조사가 필요함(부품 단위로 전수조사, 시험, 인증 절차를 거치며 각 부품은 이력 추적, 검사 성적서까지 관리됨)
- 바다에 사는 고래 수 : 고래 수를 모두 파악하기 어려움
- 암 발생률 통계 연구를 위한 환자의 암 진단 : 암 발생률의 통계 연구 목적의 경우 전국민을 대상으로 전수조사 할 수 없음
- 전구의 성능 조사 : 전구의 경우 그 개수가 많아 전수조사를 할 수 없음



확률변수의 기댓값, 분산, 표준편차의 성질

a, b, c : 상수, X, Y : 독립인 두 확률변수

기댓값의 성질

- $E(a) = a$
- $E(X \pm Y) = E(X) \pm E(Y)$
- $E(XY) = E(X) \times E(Y)$
- $E(aX) = aE(X)$
- $E(aX \pm b) = aE(X) \pm b$
- $E(aX \pm bY) = aE(X) \pm bE(Y)$
- $E(aX^2 \pm bX \pm c) = aE(X^2) \pm bE(X) \pm c$

표준편차의 성질

- $\sigma(X) = \sqrt{Var(X)} = \sqrt{E(X^2) - \{E(X)\}^2}$
- $\sigma(aX + b) = |a|\sigma(X)$

분산의 성질

- $Var(X) = E(X^2) - \{E(X)\}^2$
- $Var(a) = 0$
- $Var(X \pm Y) = Var(X) + Var(Y)$
- $Var(aX) = a^2Var(X)$
- $Var(aX \pm b) = a^2Var(X)$
- $Var(aX \pm bY) = a^2Var(X) + b^2Var(Y)$

분산의 성질 수정

분산의 성질 수정

두 확률변수가 독립이 아닐때 분산의 성질

- $Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y)$
- $Var(X - Y) = Var(X) + Var(Y) - 2Cov(X, Y)$
- $Cov(X, Y) = E[(X - E(X))(Y - E(Y))]$
 $= E(XY) - E(X)E(Y)$




2. [3][6] 주성분분석에 대한 설명으로 옳바르지 않은 것은?

- 1 주성분분석은 분포된 데이터들의 특성을 설명할 수 있는 하나 또는 복수 개의 특징을 찾는 것을 의미한다
- 2 변수들의 공분산 행렬이나 상관행렬을 이용한다
- 3 음수를 포함하지 않은 두 행렬의 곱으로 분해하는 알고리즘을 적용한다
- 4 원본 데이터 행렬은 정방행렬일 필요가 없으며, 고윳값분해에는 행과 열의 수가 동일한 정방행렬만 사용 가능하다.

보기 4 수정

음수 미포함 행렬분해 : 음수를 포함하지 않은 두 행렬의 곱으로 분해하는 알고리즘
(4번 보기 주의)

PCA를 할 때 원본 데이터는 행, 열의 수가 같을 필요가 없고, 이용하는 공분산 행렬, 상관행렬이 정방행렬이라는 것입니다. 보기에서 “행과 열의 수가 동일한 정방행렬만 사용 가능하다.”라고 하면 원본 데이터가 정방행렬만 가능하다고 해석될 수 있어 틀린 보기로 보아 주시면 됩니다. 고윳값 분해에 사용하는 것이 정방행렬만 가능한 것입니다.



10. [3] 변수 변환 기법 중 Box-Cox 변환 기법에 대한 설명으로 올바르지 않은 것은?

[문제 전체 다시 보기](#)

- 1 데이터의 스케일이 심하게 차이가 나는 경우 그 차이를 그대로 반영하기 보다는 상대적 특성이 반영된 데이터로 변환하는 과정이다.
- 2 오른쪽 꼬리가 긴 분포를 가진 변수의 왜도를 감소시키기 위해 로그 변환을 수행하기도 한다
- 3 여러 변수 간의 조합이나 조건을 활용하여 새로운 개념의 변수를 만들어, 분석 모형의 설명력과 성능을 향상시키는 과정이다.
- 4 변수에 제곱근을 취하면 오히려 선형적인 특징을 가지게 되어 의미를 해석하기 쉬워진다

Box Cox 변환

- 데이터를 정규분포에 가깝게 만들거나 데이터의 분산을 안정화 하는 것
 - 정규성을 가정하는 분석법을 사용하기 전에 활용하는 데이터 전처리 기법
 - 데이터가 모두 양수인 경우에만 사용 가능
- 3번의 설명은 파생변수에 대한 설명이다.



3. [9] 다음과 같은 자료는 어떤 종류의 데이터인가?

Company	Revenue	Employee	Year
A	100	50	2024
B	95	60	2024
C	80	55	2024
D	75	40	2024
E	110	70	2024

1 횡단면 데이터(Cross-Sectional Data)

2 대화형 데이터(Interactive Data)

3 패널 데이터(Panel Data)

4 시계열 데이터(Time Series Data)

답 1번

횡단면 데이터

- 한 시점에서 여러 대상(사람, 회사, 국가 또는 지역 등)을 관찰한 데이터로 각 대상 간의 차이점을 비교하는데 사용됨
- 위 데이터는 시간적 변화를 다루지 않고 특정 시점에 여러 회사의 정보를 수집한 것이므로, 한 시점에서의 여러 개체 간의 차이를 비교하였으므로 횡단면 데이터의 특징을 갖고 있음

패널 데이터(Panel Data)

Company	Revenue	Employee	Year
A	100	50	2024
B	95	40	2024
C	80	55	2024
A	125	55	2025
B	100	42	2025
C	90	58	2025

시계열 데이터(Time Series Data)

Year	Revenue	Employee	Company
2018	100	50	A
2019	105	52	A
2020	110	55	A
2021	115	56	A
2022	120	58	A

뒤의 내용은 한 번 확인하고 가시는 것을 추천 드립니다.



- ❖ 본강의 학습이 종료되신 분들은 ‘문제풀이’에 집중하여 주세요.
- ❖ 그리고 2026년 신규 교안을 미리 제공해 드렸는데 시간이 되시는 분들은 꼭 살펴 보시고, 시간이 없는 분들은 학습했던 내용에 집중하시면 됩니다.
- ❖ 요약변수/파생변수 (좀 더 세부적인 내용이 있으니 보아주세요)
- ❖ 시간 관련 데이터 종류, 시공간 데이터의 특징
- ❖ 히트맵(관계시각화, 비교시각화) 구분
- ❖ 결측치 처리 방법



파생 변수(Derived Variable)의 개념

- 기존 데이터의 변수들을 가공, 연산하여 새로운 의미를 갖은 변수를 새롭게 생성한 것으로 원본 데이터와 동일한 행의 수를 유지함
- 데이터 분석 및 모델링에서 데이터의 의미를 풍부하게 하고 모델의 성능을 개선하기 위해 사용됨
- 데이터의 특징을 강화하고, 패턴을 탐지하며, 모델 성능 개선에 도움이 될 수 있음
- 의미 있는 변수 생성을 위해 도메인 지식과 많은 실험이 필요할 수 있음
- 너무 많은 파생변수를 생성하면 오히려 모델이 과대적합(overfitting)될 위험이 있음
- 파생 변수는 다양한 모델에 공통적으로 적용될 수 있지만, 모델의 특성과 데이터의 특성에 따라 적합하게 정보를 제공하거나 제공하지 않을 수도 있으므로 주의하여 사용해야 함 (정보 제공 효과가 다를 수 있음)
- 파생 변수는 매우 주관적일 수 있으므로 논리적 타당성을 갖추어 개발해야 함

UNIT 35-02. 파생 변수, 요약 변수



파생 변수의 종류

단위 변환	- 변수의 단위 또는 척도 변환하여 생성하는 방식 예) 분 → 시간, 100cm → 1m, USD → KRW(미화→ 한화), 나이 → 연령대
요약 통계량 변환	- 요약 통계량을 활용하여 생성하는 방식(합계, 평균, 최대, 최소, 개수, 비율 등) 예) 고객별 누적 방문 횟수, 고객별 총 구매액, 고객별 최대 구매액, 지역별 매출 비율, 지역별 평균매출
변수 분해	- 다양한 정보를 포함한 하나의 값을 분해하여 여러 정보로 나누어 생성하는 방식 예) 주민등록번호 → (나이 성별), 날짜 → (년 월 일 요일)
변수 결합	- 다양한 함수 등 수학적 결합을 통해 새로운 변수를 생성하는 방식 예) 키, 몸무게 정보 사용하여 BMI 구하기, $BMI = (몸무게 / 키(m)^2)$
교호작용 활용 변수생성	- 두 개 이상의 독립변수(설명변수)가 종속변수에 미치는 영향이 서로 영향을 주는 현상 (모형 생성시 포함) - 즉, 하나의 독립변수가 종속변수에 미치는 효과가 다른 독립변수의 수준에 따라 달라지는 경우 => 교호작용

고객 ID	주문 ID	구매금액	고객 평균구매금액 (요약 통계량 변환)
A001	01001	10000	12500
A001	01002	15000	12500
A002	01003	20000	20000

몸무게(kg)	키(cm)	수입(USD)	생년월일	근무시간(분)
70	175	2000	1990-05-10	510
키(m)	BMI	수입(KRW)	출생연도	근무시간(시간)
단위 변환	변수 결합	단위 변환	변수분해	단위 변환
1.75	22.86	2000	1990	8.5



요약 변수(Summary Variable)의 개념

- 여러 관측값(행) 또는 범주를 집계하여 집합적인 정보를 나타내는 변수로 그룹별 집계 통계량을 구하는 것
- 여러 데이터를 하나의 값으로 요약하여 분석에 활용하기 쉽게 만든 변수
- 여러 분석 모델에서 공통적으로 사용될 수 있어 재사용성이 높음
- 집계를 통해 용량을 줄여 데이터 분석의 효율성을 높이고, 데이터 마트에서 핵심적인 정보를 제공하는 중요한 역할을 함
- 원본 데이터의 특징을 잘 파악하여 유용한 요약 변수를 만들어내는 것이 중요함
- 예) 단어 빈도, 고객 ID별 총 구매금액, 고객 ID별 평균 구매금액, 시간대별 방문자 수, 분기별 매출합계, 최대값/최소값

고객 ID	주문 ID	구매금액
A001	01001	10000
A001	01002	15000
A002	01003	20000
A002	01004	10000
A003	01005	5000

고객 ID	고객 ID별 총구매금액	고객 ID별 평균구매금액	고객 ID별 구매횟수
A001	25000	12500	2
A002	30000	15000	2
A003	5000	5000	1

← 고객의 등급화, 구매 패턴 탐색 등의 분석이 가능해짐

요약 변수(Summary Variable)


데이터 마트(Data Mart)에서의 요약 변수 : 실무자들이 빠르고 쉽게 의사결정을 내릴 수 있도록 데이터를 제공하는 저장소로, 요약 변수는 그 데이터를 핵심 지표 중심으로 요약해주기 때문에, 데이터 마트 안에서 가장 자주 활용되고 재사용 가치가 높은 변수임



파생 변수와 요약 변수의 비교

항목	요약변수	파생변수
목적	데이터의 통계적 요약	새로운 정보 추출
형태	그룹별 하나의 수치/ 집계값	새로운 컬럼(변수)
활용 시점	분석 중 요약용(일시적인 사용)	분석, 모델링에 사용(지속적인 사용)
예	전체 평균, 최대값, 최소값, 개수 합계 등	체중/키를 사용한 BMI계산, 날짜를 사용한 요일

UNIT 25-02. 데이터 시각화 개요



시간 데이터의 종류

횡단면 데이터 Cross-Sectional Data	- 한 시점에서 여러 대상(사람, 회사, 국가 또는 지역 등)을 관찰한 데이터 - 횡단면 데이터의 분석은 각 대상 간의 차이점을 비교하는데 사용됨 예) 2024년의 회사 A, B, C의 매출 데이터 (동일한 년도, 여러 회사)
시계열 데이터 Time-Series Data	- 하나의 대상에 대해 시간에 따라 측정된 데이터 - 하나의 대상만을 관측하는 종단면(패널) 데이터의 특별한 경우의 데이터 예) 2018-2022년에 대한 회사 A의 매출 데이터(변화되는 년도, 한 개 회사)
패널 데이터 Panel Data	- 여러 대상에 대해 여러 시점에 걸쳐 관찰된 데이터 - 시계열 데이터와 횡단면 데이터를 결합한 형태의 데이터 예) 2018-2022년에 대한 회사 A, B, C의 매출 데이터 (변화되는 년도, 여러 회사)

횡단면 데이터(Cross-Sectional Data)

Company	Revenue	Employee	Year
A	100	50	2024
B	95	60	2024
C	80	55	2024
D	75	40	2024
E	110	70	2024

시계열 데이터(Time Series Data)

Year	Revenue	Employee	Company
2018	100	50	A
2019	105	52	A
2020	110	55	A
2021	115	56	A
2022	120	58	A

패널 데이터(Panel Data)

Year	Company	Revenue
2018	A	100
2019	A	105
2020	A	110
2021	A	115
2022	A	120
2018	B	90
2019	B	95
2020	B	100
2021	B	105
2022	B	110
2018	C	80
2019	C	82
2020	C	85
2021	C	88
2022	C	92



시공간 데이터의 이해


- 공간 데이터에 대한 시간의 흐름을 결합한 데이터
- 다차원 구조이며, 각 시간과 공간의 두 가지 종류의 변수를 포함하는 데이터
- 시공간 데이터는 공간 데이터와 시간 데이터를 따로 추출할 수 있음
- 공간 데이터와 시간 데이터는 각각의 특성과 구조를 가지고 있으며, 서로 다른 관리 및 분석 방법이 필요할 수 있음
- 일반적으로 공간 데이터와 시간 데이터는 별도로 관리되며, 이 경우 서로 독립관계로 계산에 의한 추출을 할 수 없음
- 시공간 데이터의 예 : 차량의 GPS (차량이 지나가는 위치 좌표와, 해당 좌표를 지나간 시점의 데이터), 기상 데이터 (위도, 경도, 고도 및 관측 시간에 따른 기상 조건 등이 포함되는 데이터)
- 지리 정보 시스템(GIS), 기상학, 환경 과학, 우주 탐사, 배달 경로 최적화, 위치 기반 마케팅 등 다양한 분야에서 사용

시간 정보			공간 정보				
버스ID	날짜	시간	위도(Lat)	경도(Lon)	정류장명		
B001	2025-07-18	08:05:00	37.5721	126.9769	광화문역	활용: 이동 경로 추적, 정체 분석, 경로 최적화 등	



공간 정보		시간 정보		공간 정보			
관측소ID	지역	관측일자	관측시각	위도	경도	기온(°C)	강수량(mm)
ST101	서울 종로구	2025-07-18	08:00	37.57	126.98	26.3	0.0

활용: 날씨 패턴 분석, 지역별 이상 기후 감지 등

범주형 데이터에 사용되는 주요 그래프




- 단일 범주형 변수
Bar Chart, Pie Chart, Pareto Chart
- 두 개 이상의 범주형 변수
Stacked Bar Chart, Mosaic Plot, Heatmap



관계 시각화 (모자이크 플롯)



모자이크 플롯(Mosaic Plot)

- 범주형 변수 간의 상호관계 파악에 사용함
- 2개 이상의 범주형 변수로 구성
- X, Y 축이 모두 범주형 변수로 사각형의 크기는 해당 범주 조합의 비율 또는 빈도수를 나타냄



히트맵(Heatmap)

- 여러 변수의 관계 시각화에 사용함, 색 및 농도를 사용하여 값의 크기를 표시
- 관계 시각화로 사용되는 경우 X, Y 축이 동일하며, 변수 간 상관성을 표시함(상관분석 결과):
- 비교 시각화로 사용되는 경우 X, Y 축이 다르며, 범주별 값 크기 비교에 사용함




UNIT 26-07. 데이터 시각화의 분류

비교 시각화 (평행 차트, 스타 차트, 히트맵)


평행 차트(Parallel Chart)

여러 개의 수치형 변수를 수직 축으로 나란히 배열하고, 한 개체의 값을 선으로 연결하여 표현하는 차트, 패턴, 군집, 이상치를 시각적으로 탐색




스타, 레이다, 거미줄 차트 Star, Spider, Rader Chart

- 측정 목표에 대한 평가항목이 다수 일 때 사용
- 변수의 수만큼 축을 그리고 각 축에 측정값 표시, 항목간 비율 및 균형, 경향을 알 수 있음



히트 맵(Heatmap)

두 개 범주형 변수 범주별 비교 시각화에 사용함, 색 및 농도를 사용하여 값의 크기 표시



<https://www.r-graph-gallery.com/>



결측값 처리 방법

삭제 또는 다양한 대치 기법을 활용하여 결측값을 보완하고, 완전한 데이터셋으로 분석이 가능하도록 함

단순 대치법					고급 대치법	
완전 분석법 (삭제 기반)	평균 대치법		단순 확률 대치법			다중 대치법 (MICE, Amelia, MCMC)
	조건부	비조건부	Hot Deck	Cold Deck	Hot & Cold 혼합방식	
					모형 기반 대치법 (회귀, KNN, Random Forest)	

단순 대치법	완전 분석법	Completes Analysis, 결측값이 포함된 관측치를 모두 제외하여 분석으로 결측치가 적을 때 사용을 고려할 수 있는 방법임
	평균 대치법	- Mean Imputation, 결측값을 자료의 적절한 평균값으로 대치하여 완전한 자료로 만들어 분석 - 비조건부 평균 대치법: 데이터의 평균, 중앙값(이상값이 있는 경우 사용), 최빈값 등으로 단순 대치 - 조건부 평균 대치법: 같은 그룹, 같은 범주, 같은 성별, 같은 연령대 등의 평균으로 대치하는 방법으로 결측값이 다른 변수와 관련되어 발생하는 경우 조건부 평균 대치법이 더 적합
	단순 확률 대치법	- Single Stochastic Imputation, 평균 대치법에서 추정된 표준오차의 과소추정문제를 보완하고자 고안된 방법으로 평균 대치법에 적절한 확률값을 부여하여 대치하는 방법 - Hot-Deck: 현재 진행 중인 연구에서 비슷한 성향을 가진 응답자의 자료로 대치 - Cold-Deck: 외부 데이터나 과거 연구에서 유사 조건의 관측값을 참조하여 대치



고급 대치법	모형 기반 대치법	- Model-based Imputation, 데이터를 예측하는 통계 또는 기계학습 모형을 사용하여 결측값 대치 - 선형회귀, KNN, 랜덤-포레스트, 자기회귀(AR) 모델, 시계열 예측모형 등으로 대치하는 방법
	다중 대치법	- Multiple Imputation, 결측값을 통계적 모형에 기반하여 무작위로 대치하고, 이 과정을 여러 번 반복하여 서로 다른 가상적 완전 자료(m개)를 생성한 뒤, 여러 분석 결과를 종합하는 방법으로 (대치 → 분석 → 결합)의 단계로 구성됨 - 무작위 요소를 포함한 예측을 여러 번 반복 → 대치값의 불확실성까지 반영 - MICE, Amelia, Bayesian Imputation, MCMC, Random Forest Imputation 등이 있음

결측값 처리 방법의 문제점



- 어떤 방식으로 결측값을 처리하더라도 이는 '추정치'에 불과하며, 실제 존재했을 값과 **동일하다는 보장은 없음**
- 모든 결측값 처리 방법은 **불확실성, 왜곡, 정보 손실 등의 리스크**를 동반함
- 원래 데이터의 평균, 분산 등의 통계적 특성이 변경될 수 있어, **분석의 신뢰성을 저하시킬 수 있음**

완전 분석법	일부 자료 손실로 인한 효율성 저하 및 통계적 타당성 문제 발생
평균 대치법/모형 기반 대치법	한 개의 추정치로 결측값을 대치함으로써 통계량의 표준오차가 과소 추정되는 문제가 있음
다중 대치법	여러 번 대치, 분석하는 작업으로 인한 절차 복잡성과 추정량 계산의 복잡성, 분석 결과 결합의 난해함의 문제가 있음



자기회귀(AR) 모델을 사용한 결측치 대체

- 데이터의 시계열 구조를 얼마나 잘 복원하느냐에 따라 대체 후 분석 결과의 분산 유지 여부, 상관성 보존 등에 영향을 줌
- 대체된 값들이 예측 평균에 수렴함에 따라 **상관성은 인위적으로 높아지고, 분산은 줄어 들 수 있음**
- AR이나 회귀 기반 대체 시, 예측 모델이 특정 변수에 의존하게 되면, 그 변수와 결측치 대체 대상 변수 간 **상관성이 실제보다 과도하게 강화될 수 있음** (왜곡된 신호)
- 예측된 값이 평균 근처로 몰리면서 데이터의 전체 분산이 **데이터의 분산이 줄어 들 수 있음**
- 결측값 처리 이후에 상관성이 높아지고 분산이 줄어드는 현상은 **통계적 왜곡의 징후** 일 수 있어, 불확실성을 반영할 필요가 있음
- 결측값의 추정 오차나 불확실함을 분석 결과(표준오차, 신뢰구간 등)에 반영한다는 의미





결측값 상황별 처리 방법

범주형 변수	최빈값으로 대체하여 분석 (예) 설문조사에서 혈액형
연속형 변수	- 평균, 중앙값, 회귀 또는 KNN 기반 대체 등으로 처리 (예) 수입(income), 나이(age) - 분포가 비대칭일 경우 : 중앙값 사용을 권장
높은 결측률, 낮은 중요도	- 변수를 제거하여 결측 문제 해소 (정보 손실 우려 낮음) - 결측값이 많다고 무조건 변수를 제거하면 잠재적인 중요한 정보 손실 우려가 있어 변수 영향력을 함께 고려함
높은 결측률, 높은 중요도	변수를 보존하며, 고급 대체 기법을 사용함
의미 있는 누락	'미응답'과 같은 새로운 범주로 처리 (예) 연봉의 경우 민감해서 입력을 안 할 수 있음
시계열 데이터	- 시간 흐름을 유지하기 위한 보간(interpolation) 또는 시계열 모델 기반 대체법 사용 (예) IoT 센서 데이터, 금융 데이터

보간(Interpolation) 기법이란?

- 일정한 순서가 있는 데이터(주로 시계열)에서 중간에 비어 있는 값을 주변 값을 바탕으로 추정해서 채우는 방법